

基于深度学习的 太阳能电池片表面缺陷检测方法^{*}

王宪保^{1 2} 李 洁¹ 姚明海¹ 何文秀¹ 钱云涛²

¹(浙江工业大学 信息工程学院 杭州 310023)

²(浙江大学 计算机科学与技术学院 杭州 310027)

摘 要 目前对太阳能电池片的缺陷检测仍依赖人工完成,很难通过传统的 CCD 成像系统自动识别.作为一种多层神经网络学习算法,深度学习因对输入样本数据强大的特征提取能力而受到广泛关注.文中提出一种基于深度学习的太阳能电池片表面缺陷检测方法,该方法首先根据样本特征建立深度置信网络(DBN),并训练获取网络的初始权值;然后通过 BP 算法微调网络参数,取得训练样本到无缺陷模板之间的映射关系;最后利用重构图像与缺陷图像之间的对比关系,实现测试样本的缺陷检测.实验表明 DBN 能较好地建立上述映射关系,且准确、快速地进行缺陷检测.

关键词 深度学习,缺陷检测,限制玻尔兹曼机(RBM),深度置信网络(DBN)

中图法分类号 TP 391

Solar Cells Surface Defects Detection Based on Deep Learning

WANG Xian-Bao^{1 2}, LI Jie¹, YAO Ming-Hai¹, HE Wen-Xiu¹, QIAN Yun-Tao²

¹(College of Information Engineering, Zhejiang University of Technology, Hangzhou 310023)

²(College of Computer Science and Technology, Zhejiang University, Hangzhou 310027)

ABSTRACT

Defects of solar cells are detected mainly by manual operation, and they are difficult to be detected automatically by traditional charge-coupled device(CCD) imaging system. As a training multi-layer neural network, deep learning draws great attention due to its strong ability to extract features from input sample data. A method for solar cells surface defects detection based on deep learning is proposed. Firstly, deep belief networks(DBN) are established and trained according to the sample features to obtain the initial weights of the networks. Then, the traditional BP algorithm is conducted to fine-tune the network parameters to get the mapping relationship between the training samples and the defect-free template. Finally, the defects of testing samples are detected by the contrast between the reconstruction image and the defect image. Experimental results show that DBN perfectly establishes the mapping

^{*} 国家自然科学基金项目(No. 61070113)、浙江省自然科学基金项目(No. LY14F030009)资助

收稿日期: 2014-01-07; 修回日期: 2014-02-25

作者简介 王宪保(通讯作者),男,1977 年生,博士,讲师,主要研究方向为模式识别、神经网络、图像处理及其在缺陷检测中的应用等. E-mail: wxb@zjut.edu.cn. 李洁,女,1988 年生,硕士研究生,主要研究方向为模式识别、图像处理、图像理解等. 姚明海,男,1963 年生,教授,博士生导师,主要研究方向为模式识别、智能控制、物联网等. 何文秀,女,1979 年生,博士研究生,讲师,主要研究方向为人工智能、无线传感网络. 钱云涛,男,1968 年生,教授,博士生导师,主要研究方向为机器学习、模式识别、图像处理.

relationship, and it can quickly detect defects with a high accuracy.

Key Words Deep Learning, Defect Detection, Restricted Boltzmann Machine (RBM), Deep Belief Network (DBN)

1 引言

深度学习模拟人脑分析问题的过程,通过组合、学习低层数据形成更抽象的高层特征表示(属性、类别等),以提高后续识别、分类的准确性^[1].自Hinton等^[2]于2006年提出以来,由于其在手写、语音识别及人脸识别等领域取得较好的实验效果,从而受到各国学者的持续关注.

传统的机器学习是浅层学习结构,它仅将原始输入信号变换到特定问题空间,形成一种简单的特征结构^[3].典型结构包括隐马尔科夫模型、支持向量机、最大熵模型、条件随机场等.它们的局限性是在有限样本和计算能力情况下,对复杂函数的表示能力有限,针对复杂分类问题其泛化能力受到一定制约.而深度学习可实现复杂函数逼近,表征输入数据分布式表示,展现较强的从大量样本集中学习数据集本质特征的能力^[4-5].

深度学习在信号处理中的应用对象主要包括语音^[6-7]、图像、视频及文本等.在图像方面,深度学习最早用在手写体数据集 MINST 的识别上,取得当时的最好结果,将错误率降低至 1.2%.2012 年 10 月, Hinton 等在 ImageNet 问题上将深度学习和卷积神经网络(Convolutional Neural Networks, CNN)结合,将错误率从原先的 26% 降低至 15%.此外深度学习在人体行为预测^[8]、医疗诊断、药物研制、广告搜索及自动驾驶等方面都取得了较好的研究成果.

国内的深度学习研究较晚,除在传统的人脸识别^[9]方面的研究之外, Wang 等^[10]利用自动编码器实现视觉跟踪,使系统在复杂背景下也能保持良好的跟踪效果.陈宇等^[11]提出一种利用深度置信网络(Deep Belief Networks, DBN)模型进行基于特征的实体关系抽取方法,在文本实体之间语义关系的识别方面取得比 SVM 和 BP 网络更好的实验结果.

太阳能转换系统中重要组成部分的太阳能电池片,由于其较低的材料成本、制造成本和良好的转换效率和可用寿命,受到大量生产厂商的青睐.然而电池片表面缺陷的细微性和隐秘性,使检测变得异常困难.近年来, Tsai 等^[12]提出基于傅立叶重构技术的一种自我参照法来实现太阳能电池片缺陷的检

测. Bastari 等^[13]提出一种对电致发光图像中暗色缺陷区域进行纹理分析,从而自动分类出有缺陷和无缺陷的电池片的方法.文献[14]提出通过诊断太阳能电池片的电致发光图像的温度差来检测缺陷的方法.

本文提出一种基于深度学习的太阳能电池片缺陷检测方法.该方法首先通过学习大量缺陷样本,得到训练样本到无缺陷模板之间的映射关系,然后利用重构图像与缺陷图像之间的对比,实现样本的缺陷检测.

2 深度学习模型的结构

深度学习模型主要有 DBN^[15]和 CNN^[1]两种,其中 DBN 是一种无监督的机器学习模型,而 CNN 是一种有监督的机器学习模型.由于本文是在无监督情况下训练样本,所以采用 DBN 来建模.

2.1 限制玻尔兹曼机

限制玻尔兹曼机(Restricted Boltzmann Machine, RBM)^[16]是 Smolensky 于 1986 年提出的一种生成式随机神经网络.它来源于对玻尔兹曼机(Boltzmann Machines, BM)^[17]的一种改进.虽然 BM 具有强大的无监督学习能力,但训练时间较长,且无法准确计算 BM 所表示的分布,也很难得到服从 BM 所表示分布的随机样本^[18].因此 RBM 被引入解决这一问题.

在 RBM 中,神经元是随机的,且只有未激活和激活两种状态,一般用二进制的 0 和 1 表示,取值根据概率统计法则决定. RBM 与 BM 一样,具有一个可见层,一个隐藏层,如图 1 所示.但区别在于其层内无连接,这种结构使得 RBM 在给定可见层单元状态时,各隐藏层单元的激活条件独立;反之在给定隐藏层单元状态时,可见层单元的激活条件也独立.




图 1 RBM 模型的结构

Fig. 1 Structure of RBM model

一个有 n 个可见单元

$$\mathbf{v} = (v_1, v_2, \dots, v_n)$$

和 m 个隐藏单元

$$\mathbf{h} = (h_1, h_2, \dots, h_m)$$

的 RBM 能量函数定义为

$$E(\mathbf{v}, \mathbf{h}) = - \sum_{i=1}^n a_i v_i - \sum_{j=1}^m b_j h_j - \sum_{i=1}^n \sum_{j=1}^m v_i w_{ij} h_j,$$

其中 \mathbf{v} 和 \mathbf{h} 分别为可视层和隐藏层的状态, v_i 为第 i 个可见单元的状态, h_j 为第 j 个隐藏单元的状态, a_i 为可见单元 i 的偏置, b_j 为隐藏单元 j 的偏置, w_{ij} 为可见单元 i 与隐藏单元 j 之间的连接权重。

RBM 的状态符合正则分布的形式, 当上述各参数确定时, RBM 处于状态 \mathbf{v}, \mathbf{h} 的概率为

$$P(\mathbf{v}, \mathbf{h}) = \frac{1}{Z} \exp(-E(\mathbf{v}, \mathbf{h})),$$

其中

$$Z = \sum_{\mathbf{v}, \mathbf{h}} \exp(-E(\mathbf{v}, \mathbf{h}))$$

是归一化因子, 也称为配分函数。

当给定可见单元状态时, 各隐藏单元的激活状态之间是条件独立的, 由此可得第 j 个隐藏单元的激活概率为

$$P(h_j = 1 | \mathbf{v}) = \sigma\left(b_j + \sum_i v_i w_{ij}\right), \quad (1)$$

其中

$$\sigma(x) = (1 + e^{-x})^{-1}$$

为 sigmoid 激活函数。根据 RBM 的对称结构, 同理可得第 i 个可见单元的激活概率为

$$P(v_i = 1 | \mathbf{h}) = \sigma\left(a_i + \sum_j w_{ij} h_j\right). \quad (2)$$

为得到网络参数 w_{ij}, a_i 和 b_j , 需拟合给定的训练数据, 用极大似然法最大化式 (2), 对数似然函数如下:

$$\theta^* = \arg \max_{\theta} L(\theta) = \arg \max_{\theta} \sum_{t=1}^T \log P(\mathbf{v}^{(t)} | \theta),$$

其中

$$\theta = \{w_{ij}, a_i, b_j\}.$$

使用梯度下降法可推导出权值的更新公式:

$$\begin{aligned} \Delta w_{ij} &= \mathcal{E}(\langle v_i h_j \rangle_{\text{data}} - \langle v_i h_j \rangle_{\text{model}}), \\ \Delta a_i &= \mathcal{E}(\langle v_i \rangle_{\text{data}} - \langle v_i \rangle_{\text{model}}), \\ \Delta b_j &= \mathcal{E}(\langle h_j \rangle_{\text{data}} - \langle h_j \rangle_{\text{model}}), \end{aligned} \quad (3)$$

其中 \mathcal{E} 表示学习率, 经验取值 $\mathcal{E} = 0.1$ 。式 (3) 的第 1 项是给定样本数据的期望, 易计算。第 2 项是模型本身的期望, 不易直接得到。因此 Hinton^[19] 提出一种快速算法, 即对比分歧 (Contrastive Divergence,

CD) 算法。该算法只要迭代 k (通常 $k=1$) 次, 就可获得较好估计。CD 用训练数据初始化可见层, 并利用式 (1) 计算所有隐藏层单元的状态。隐藏层单元的状态确定后, 再根据式 (2) 确定所有可见层单元的状态, 这样就产生对可见层的一个重构。经 CD 计算后, 式 (3) 更改为

$$\Delta w_{ij} = \mathcal{E}(\langle v_i h_j \rangle_{\text{data}} - \langle v_i h_j \rangle_{\text{recon}}),$$

$$\Delta a_i = \mathcal{E}(\langle v_i \rangle_{\text{data}} - \langle v_i \rangle_{\text{recon}}),$$

$$\Delta b_j = \mathcal{E}(\langle h_j \rangle_{\text{data}} - \langle h_j \rangle_{\text{recon}}),$$

其中 $\langle \cdot \rangle_{\text{recon}}$ 表示重构后模型定义的概率分布。基于 CD 的 RBM 学习算法的主要步骤可描述如下。

算法 1 基于 CD 的 RBM 算法

输入 训练样本 \mathbf{x}_0 , 学习率 \mathcal{E} , 隐藏层数 m

初始化 可见层单元初始状态 $\mathbf{v}_1 = \mathbf{x}_0$, 可见层和隐藏层之间的连接权重 \mathbf{w} 、可见层的偏置 \mathbf{a} 和隐藏层的偏置 \mathbf{b} 为随机的较小数值

备注 隐藏层的 $P(\mathbf{h}_2 = \mathbf{1} | \mathbf{v}_2)$ 是隐藏层各单元 $P(h_{2i} = 1 | v_2)$ 的向量表示

训练过程

For $j = 1, 2, \dots, m$ (对隐藏层单元 j)

计算

$$P(h_{1j} = 1 | \mathbf{v}_1) = \sigma\left(b_j + \sum_i v_{1i} w_{ij}\right)$$

从 $P(h_{1j} = 1 | \mathbf{v}_1)$ 采样 $h_{1j} \in \{0, 1\}$

End

For $i = 1, 2, \dots, n$ (对可见层单元 i)

计算

$$P(v_{2i} = 1 | \mathbf{h}_1) = \sigma\left(a_i + \sum_j w_{ij} h_{1j}\right)$$

从 $P(v_{2i} = 1 | \mathbf{h}_1)$ 采样 $v_{2i} \in \{0, 1\}$

End

For $j = 1, 2, \dots, m$ (对隐藏层单元 j)

计算

$$P(h_{2j} = 1 | \mathbf{v}_2) = \sigma\left(b_j + \sum_i v_{2i} w_{ij}\right)$$

End

更新参数

$$\mathbf{w} \leftarrow \mathbf{w} + \mathcal{E}(\mathbf{h}_1 \mathbf{v}_1' - P(\mathbf{h}_2 = \mathbf{1} | \mathbf{v}_2)) \mathbf{v}_2'$$

$$\mathbf{a} \leftarrow \mathbf{a} + \mathcal{E}(\mathbf{v}_1 - \mathbf{v}_2)$$

$$\mathbf{b} \leftarrow \mathbf{b} + \mathcal{E}(\mathbf{h}_1 - P(\mathbf{h}_2 = \mathbf{1} | \mathbf{v}_2))$$

2.2 深度置信网络

DBN 是一种由多层 RBM 叠加而成的网络模型^[20]。如图 2 所示, (a) 中每个低层的 RBM 将输入数据训练后输出, 并作为高一层 RBM 的输入, 逐层

传递,构成(b)所示的DBN,在顶层形成更抽象和更具有表征能力的特征向量。与传统网络(如BP网络)相比,DBN能通过预训练得到合适的权重初值,克服因随机设置初始化参数而易陷入局部最优且训练时间长的缺点。




图2 一叠RBM和对应的DBN

Fig. 2 A stack of RBMs and the corresponding DBN

DBN的训练过程主要分为以下两步^[21-22](见图3)。

step 1 无监督地训练每层RBM,确保低层特征向量映射到高层特征空间时,尽可能多地保留特征信息;

step 2 得到前向权值和后向权值后,通过BP算法微调整个DBN的权值。




图3 DBN的训练过程

Fig. 3 Training process of DBN

3 深度置信网络缺陷检测分析

本文用深度学习网络实现太阳能电池片表面缺陷检测,其可行性如下。

陷检测,其可行性如下。

1) 太阳能电池片表面具有简单的纹理图案,在检测背景不变、检测位置固定时,无缺陷图像具有一致的纹理特征,而有缺陷图像只是在局部存在灰度差异,这些特点正好适用于DBN较强的特征抽取能力。

2) DBN把图像处理和特征提取结合为一体,较大地缩短缺陷检测时间,能更好满足在线产品检测。同时也为并行化处理提供理论基础。

3) DBN能快速完成权值训练,使其在产品背景、位置、型号发生改变时,也能满足生产需要。

4) DBN与传统识别网络相结合(通常在最上层加入一识别层)不但可实现图像处理、特征提取,还可完成模式识别,为后续的缺陷识别提供实现途径。

4 缺陷检测实现

实验中,首先归一化输入为 64×64 的二值图像,其中100幅图像为训练样本,20幅为测试样本,样本中包括有缺陷图像和无缺陷图像。然后利用算法1训练RBM连接而成的DBN,得到相应的预训练权值。最后在初始权值的基础上,用BP算法对权值进一步调整。预训练、展开和微调的过程如图4所示。

本次训练是在Intel Core i7-3770M 3.4 GHz、内存8 GB的CPU平台上,利用Matlab完成的,其中的缺陷包括裂痕、刮擦和缺角等。DBN的输入层是4 096维,4个隐藏层维度分别是1 000, 500, 250, 30。整个网络权值的获得流程如下。

1) 首先训练第1个RBM网络,即输入层4 096维和第1个隐藏层1 000维构成的网络。采用RBM优化,计算得到训练样本在隐藏层的输出值。

2) 利用1)的结果作为第2个网络训练的输入值,同样使用RBM优化,并计算网络的输出值。用同样方法训练第3个RBM网络和第4个RBM网络。

3) 将上面4个RBM网络展开连接成新的网络,且分成encoder和decoder两部分,用1)和2)得到的值给这个新网络赋初值。

4) 将最初的输入值作为网络理论的输出标签值,利用BP算法计算网络的代价函数和代价函数的偏导数,采用共轭梯度下降法优化整个网络,得到最终的网路权值。

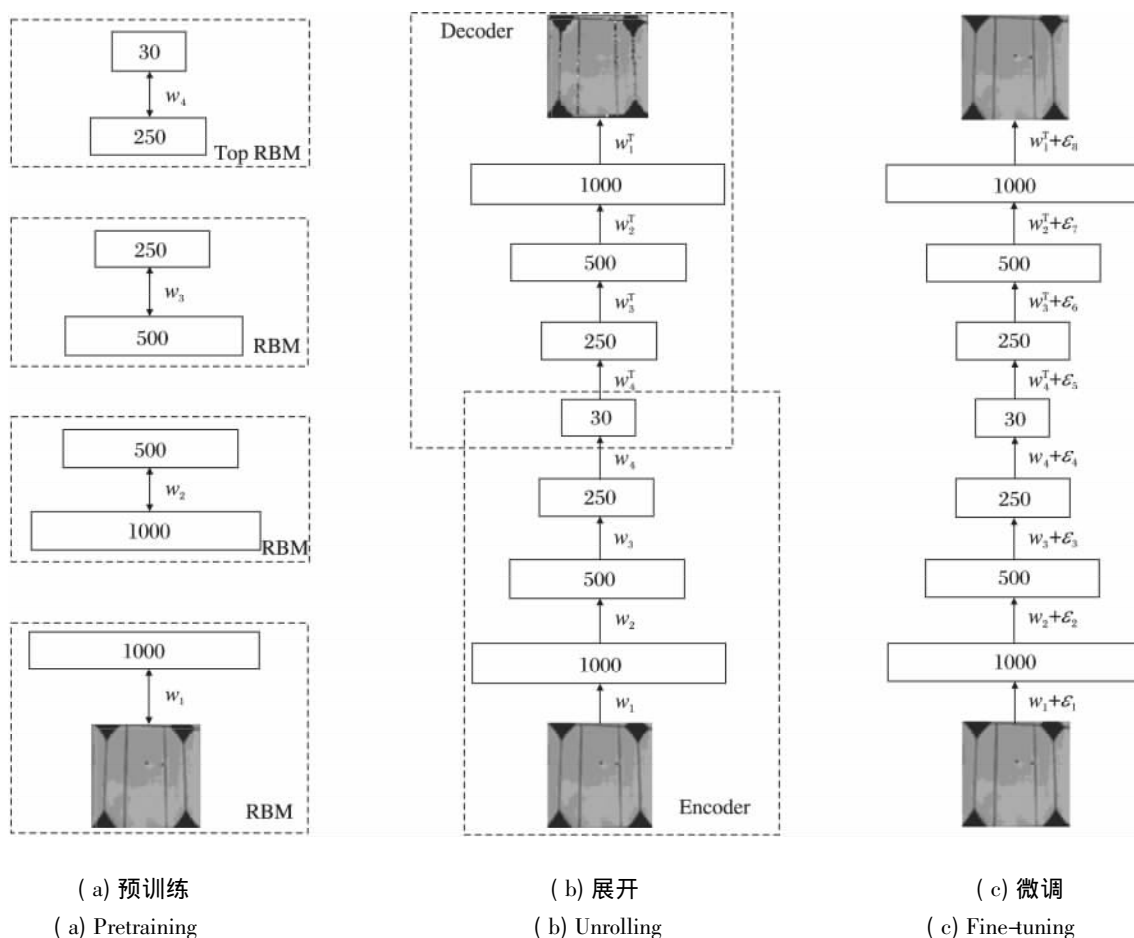


图4 缺陷检测的 DBN 学习过程

Fig. 4 Learning process of DBN in defect detection

5 实验及结果分析

图5 分别是待检测太阳能电池片的无缺陷图像和缺陷图像, 其中在缺陷图像(b)中, 黑圈标注的分别是常见的两种缺陷类型: 裂痕和缺角. 实验结果如图6所示, (a)是训练得到的重构图像, 将它与灰度化、求补、二值化后的测试图像(见(b))对比差值后, 就可得到需要的缺陷图像(见(c)), 其中缺陷由白色标记出来. 测试图像结果如图7所示, 图7(a)、(b)分别为20张测试图像中无缺陷图像和有缺陷图像, 其中有缺陷图像中除了第2行第1列图像的缺陷因裂痕太小不太明显, 出现断点之外, 其他缺陷都能很准确地检测出来. 除此之外, 对于不清晰的缺陷也可用闭运算等形态学处理来连接相邻断点, 使缺陷更清晰. 整个实验训练时间为2597s, 其中深度学习所用时间为39.62s, 预设200次迭代的BP算法所需时间为2557s, 20张测试图像所需时间为3.01s, 平均每张检测时间为0.151s.




图5 待检测的太阳能电池片图像

Fig. 5 Images of solar cell for detection

文献[23]提出一种基于鲁棒主成分分析(Robust Principal Component Analysis, RPCA)的太阳能电池片表面缺陷检测方法, 它通过凸优化的方法对待测图像矩阵进行矩阵变换, 使之分解成无缺陷的低秩矩阵图像和有缺陷的稀疏矩阵图像. 涉及的优化算法分别有加速逼近梯度(Accelerated Proximal Gradient, APG)和非精确增广拉格朗日乘子

(Inexact Augmented Lagrange Multiplier, IALM), 本文选取其中实验结果类似但检测速度更快的 IALM 进行对比. 对于相同的输入样本, 20 张 64×64 待检测图像的实验结果如图 8 所示, 其中缺陷用白圈标记出, 而无圈标记的为无缺陷图像.

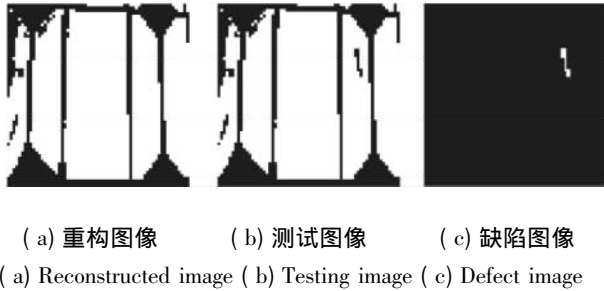


图 6 实验输入输出图像

Fig. 6 Input and output images in experiment

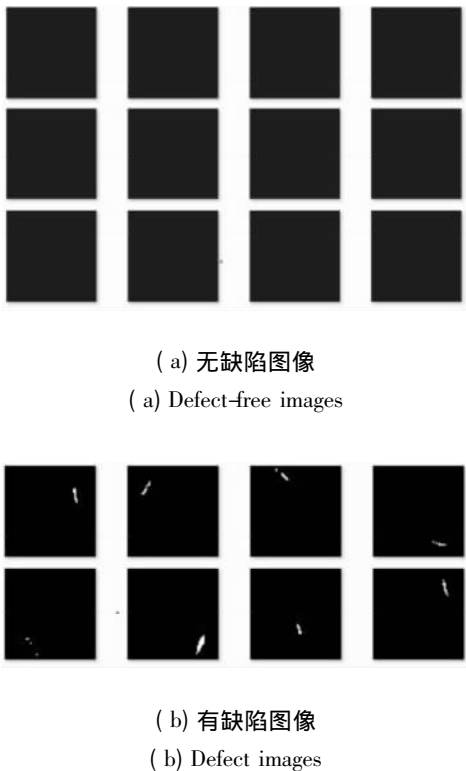


图 7 测试图像的缺陷检测结果

Fig. 7 Defect detection results of testing images

本文方法与基于 RPCA 的检测方法对比结果如下.

1) 在检测精确度几乎相同的情况下, RPCA 运行时间为 44.26 s, 平均每张检测时间为 2.21 s, 计算速度低于本文方法(平均每张检测时间为 0.151 s). 而改进的 RPCA 在降低低秩矩阵图像清晰度的代价

下, 换来的计算时间仍需 0.2 s.

2) 由图 8 可见, RPCA 检测出的缺陷清晰度、明显度不如本文方法.

3) 基于 RPCA 的检测方法只针对 4 张及以上的批量图像处理, 且前期的初始点选取需人工多次选取设定, 而本文方法可单独检测每张图片.




图 8 基于 RPCA 的太阳能电池片缺陷检测结果

Fig. 8 Defect detection results of solar cells based on RPCA

6 结束语

本文利用深度神经网络模型, 先运用 DBN 训练网络的初值, 再将重构图像与训练图像作为监督数据, 根据最大似然函数, 微调整个网络, 得到更精确的网络连接权值. 从实验结果可看出, 深度学习方法应用于太阳能电池片表面缺陷检测, 可得到较优的检测结果, 且检测速度更快. 另外该方法对于其他实物也可进行类似的检测识别, 具有一定的通用性. 但在实际应用中, 本文方法还存在一些不足, 如在工业摄像头下拍出的百万像素级图片, 这对网络训练形成很大挑战.

参 考 文 献

- [1] Bengio Y. Learning Deep Architectures for AI. Foundations and Trends in Machine Learning, 2009, 2(1): 1-127
- [2] Hinton G E, Salakhutdinov R R. Reducing the Dimensionality of Data with Neural Networks. Science, 2006, 313(5786): 504-507
- [3] Sun Z J, Xue L, Xu Y M, et al. Overview of Deep Learning. Application Research of Computers, 2012, 29(8): 2806-2810 (in Chinese)
(孙志军, 薛磊, 许阳明, 等. 深度学习研究综述. 计算机应用研究, 2012, 29(8): 2806-2810)
- [4] Bengio Y, Delalleau O. On the Expressive Power of Deep Architectures // Proc of the 22nd International Conference on Algorithmic Learning Theory. Espoo, Finland, 2011: 18-36
- [5] Yoshua B, LeCun Y. Scaling Learning Algorithms towards AI. Cambridge, USA: MIT Press, 2007
- [6] Dahl G E, Yu D, Deng L, et al. Context-Dependent Pre-trained

- Deep Neural Networks for Large-Vocabulary Speech Recognition. IEEE Trans on Audio, Speech and Language Processing, 2012, 20 (1): 30-42
- [7] Hinton G, Deng L, Yu D, *et al.* Deep Neural Networks for Acoustic Modeling in Speech Recognition: The Shared Views of Four Research Groups. IEEE Signal Processing Magazine, 2012, 29 (6): 82-97
- [8] Sungjoon C, Kim E, Oh S. Human Behavior Prediction for Smart Homes Using Deep Learning // Proc of the 22nd IEEE International Symposium on Robot and Human Interactive Communication. Gyeongju, Republic of Korea, 2013: 173-179
- [9] Lin M Z. Research on Face Recognition Based on Deep Learning. Master Dissertation. Dalian, China: Dalian University of Technology, 2013 (in Chinese)
(林妙真. 基于深度学习的人脸识别研究. 硕士学位论文. 大连: 大连理工大学, 2013)
- [10] Wang N Y, Yeung D. Learning a Deep Compact Image Representation for Visual Tracking // Proc of the 27th Annual Conference on Neural Information Processing Systems. Lake Tahoe, USA, 2013: 809-817
- [11] Chen Y, Zheng D Q, Zhao T J. Chinese Relation Extraction Based on Deep Belief Nets. Journal of Software, 2012, 23(10): 2572-2585 (in Chinese)
(陈宇, 郑德权, 赵铁军. 基于 Deep Belief Nets 的中文名实体关系抽取. 软件学报, 2012, 23(10): 2572-2585)
- [12] Tsai D M, Wu S C, Li W C. Defect Detection of Solar Cells in Electroluminescence Images Using Fourier Image Reconstruction. Solar Energy Materials and Solar Cells, 2012, 99: 250-262
- [13] Bastari A, Bruni A, Cristalli C. Classification of Silicon Solar Cells Using Electroluminescence Texture Analysis // Proc of the IEEE International Symposium on Industrial Electronics. Bari, Italy, 2010: 1722-1727
- [14] Fuyuki T, Kitiyanan A. Photographic Diagnosis of Crystalline Silicon Solar Cells Utilizing Electroluminescence. Applied Physics A: Materials Science and Processing, 2009, 96(1): 189-196
- [15] Hinton G E, Osindero S, Teh Y W. A Fast Learning Algorithm for Deep Belief Nets. Neural Computation, 2006, 18(7): 1527-1554
- [16] Smolensky P. Information Processing in Dynamical Systems: Foundations of Harmony Theory [EB/OL]. [2013-12-10]. http://www-psych.stanford.edu/~jlm/papers/PDP/Volume%201/Chap6_PDP86.pdf
- [17] Ackley D H, Hinton G E, Sejnowski T J. A Learning Algorithm for Boltzmann Machines. Cognitive Science, 1985, 9(1): 147-169
- [18] Zhang C X, Ji N N, Wang G W. Introduction of Restricted Boltzmann Machines [EB/OL]. [2013-01-11]. <http://www.paper.edu.cn/releasepaper/content/201301-528> (in Chinese)
(张春霞, 姬楠楠, 王冠伟. 受限玻尔兹曼机简介 [EB/OL]. [2013-01-11]. <http://www.paper.edu.cn/releasepaper/content/201301-528>)
- [19] Hinton G E. Training Products of Experts by Minimizing Contrastive Divergence. Neural Computation, 2002, 14(8): 1771-1800
- [20] Hu Y. Markov Chain Monte Carlo Based Improvements to the Learning Algorithm of Restricted Boltzmann Machines. Master Dissertation. Shanghai, China: Shanghai Jiao Tong University, 2012 (in Chinese)
(胡洋. 基于马尔可夫链蒙特卡罗方法的 RBM 学习算法改进. 硕士学位论文. 上海: 上海交通大学, 2012)
- [21] Sutskever I, Tieleman T. On the Convergence Properties of Contrastive Divergence [EB/OL]. [2013-12-20]. http://machinelearning.wustl.edu/mlpapers/paper_files/AISTATS2010_SutskeverT10.pdf
- [22] Hinton G E, Dayan P, Frey B J, *et al.* The "Wake-Sleep" Algorithm for Unsupervised Neural Networks. Science, 1995, 268 (5214): 1158-1161
- [23] Yao M H, Li J, Wang X B. Solar Cells Surface Defects Detection Using RPCA Method. Chinese Journal of Computers, 2013, 36 (9): 1943-1952 (in Chinese)
(姚明海, 李洁, 王宪保. 基于 RPCA 的太阳能电池片表面缺陷检测. 计算机学报, 2013, 36(9): 1943-1952)